

Nama : Zahrani Cahya Priesa

NIM : 1103223074

Mata Kuliah : Machine Learning

## **Analisa Bab 7 – Ensemble Learning & Random Forests**

Ensemble Learning adalah pendekatan untuk meningkatkan performa dengan menggabungkan beberapa model (*learners*). Metode ini dapat menurunkan variance, meningkatkan akurasi, dan membuat prediksi lebih stabil.

### **1. Pendahuluan Ensemble Learning**

Ensemble learning bekerja berdasarkan prinsip bahwa menggabungkan banyak model lebih baik daripada menggunakan satu model tunggal.

Tujuan utama ensemble:

- Mengurangi variance
- Meningkatkan akurasi
- Meningkatkan robustness model

### **2. Voting Classifiers**

#### **A. Hard Voting**

Memilih kelas berdasarkan mayoritas suara dari beberapa model.

#### **B. Soft Voting**

Menggabungkan probabilitas setiap model, lalu memilih kelas dengan probabilitas rata-rata tertinggi.

Soft voting biasanya lebih akurat karena mempertimbangkan tingkat keyakinan model.

### 3. Bagging dan Pasting

**Bagging** (Bootstrap Aggregating):

- Sampling **dengan** replacement
- Mengurangi variance
- Meningkatkan stabilitas model

**Pasting:**

- Sampling **tanpa** replacement

Keduanya melatih banyak model secara paralel.

### 4. Random Forest

Random Forest adalah ensemble dari banyak Decision Tree dengan dua mekanisme:

1. Bootstrap sampling (bagging)
2. Random subset features saat split

**Keunggulan Random Forest**

- Cepat dan stabil
- Tidak mudah overfitting
- Memiliki Feature Importance
- Mendukung OOB evaluation

**Feature Importance**

Feature importance dihitung dari seberapa banyak impurity berkurang saat fitur digunakan untuk split.

## 5. Out-of-Bag (OOB) Evaluation

Dalam bagging, sekitar 36% data otomatis tidak terambil saat bootstrap.

Data ini digunakan sebagai **validation internal**, sehingga tidak memerlukan train/validation split manual.

Kelebihan:

- Hemat data
- Lebih stabil
- Cocok untuk dataset kecil

## 6. Boosting

Boosting melatih model secara **berurutan**, di mana model berikutnya fokus memperbaiki error dari model sebelumnya.

### A. AdaBoost

- Memberi bobot lebih pada data yang salah diprediksi
- Umumnya menggunakan Decision Stump (tree depth = 1)

### B. Gradient Boosting

- Tiap model baru belajar dari **residual error**
- Digunakan pada XGBoost, LightGBM, CatBoost

Boosting lebih akurat, tetapi rentan overfitting jika tidak di-tuning dengan benar.

## 7. Stacking (Stacked Generalization)

Stacking menggabungkan beberapa *base models* (level 0), lalu hasil prediksinya digunakan untuk melatih sebuah **meta-model** (level 1).

Tahapan:

1. Latih base model
2. Kumpulkan output base model
3. Latih meta-model menggunakan output tersebut

Stacking sangat fleksibel dan populer untuk kompetisi machine learning.

## 8. Intuisi Matematis Ensemble

Jika setiap model memiliki error  $\varepsilon$  dan terdapat  $N$  model independen, maka error ensemble:

$$\varepsilon_{ensemble} = \frac{\varepsilon}{N}$$

Semakin banyak model  $\rightarrow$  semakin kecil error.

Namun, model harus **bervariasi**. Jika semua model identik  $\rightarrow$  ensemble tidak berguna.

## 9. Perbandingan Metode Ensemble

Metode	Karakteristik	Kapan Digunakan
Voting	Kombinasi beberapa algoritma berbeda	Untuk baseline yang kuat
Bagging	Mengurangi variance	Data noisy & high variance
Random Forest	Bagging + random feature	Default pilihan pertama
AdaBoost	Fokus pada instance salah	Dataset kecil–sedang
Gradient Boosting	Belajar dari residual	Akurasi tinggi
Stacking	Meta-model	Proyek besar / kompetisi

## 10. Kesimpulan Bab 7

- Ensemble learning meningkatkan akurasi dan stabilitas
- Bagging mengurangi variance, sedangkan boosting fokus pada error

- Random Forest adalah model cepat dan stabil dengan interpretasi feature importance
- Boosting lebih kuat tetapi perlu tuning
- Stacking adalah metode paling fleksibel dan powerful